

陈昊

138-0000-2468 | 广州
大模型应用开发工程师/Agent开发工程师

工作经历

星云智能科技有限公司

2024年09月 - 2026年08月

大模型应用开发工程师

广州

- 参与企业级 RAG 知识库系统开发，负责文档解析、知识入库、检索及问答链路建设，并支持 PDF、Word、Markdown 等多类型文档统一处理。
- 基于 LangChain / LangGraph 开发业务 Agent，通过 Workflow、Tool Calling 和显式状态控制实现多步骤任务执行。
- 使用 FastAPI 开发大模型应用后端服务，完成模型服务、检索服务、PostgreSQL 及 Redis 等组件之间的集成。
- 基于 Redis + Celery 实现文档解析、知识入库等耗时任务异步执行，并完善失败重试、任务状态记录等机制。
- 参与 RAG 检索与应用稳定性优化，通过多路召回、元数据过滤、Rerank、模型超时重试和结构化输出校验提升系统效果与稳定性。

启明数字科技有限公司

2023年06月 - 2024年09月

AI 应用开发工程师

深圳

- 使用 Python 和 FastAPI 开发 AI 应用后端服务，为业务系统提供文本分析、智能问答及信息抽取等能力。
- 参与公司内部知识问答系统开发，完成文档预处理、Embedding 生成、向量检索及大模型问答链路接入。
- 负责 AI 服务与现有业务系统之间的接口集成，并使用 PostgreSQL / MySQL 完成业务数据存储和查询。
- 配合算法工程师完成模型服务封装、应用侧调用及异常处理，提升 AI 能力在业务系统中的可用性。
- 参与 Docker 化部署、服务日志分析及线上问题排查，完善接口异常处理和服务可观测性。

教育经历

华南信息工程大学

2019年09月 - 2023年06月

计算机科学与技术 本科

专业技能

- 大模型与Agent**：熟悉 LangChain、LangGraph 等大模型应用开发框架；熟悉 Function Calling / Tool Calling、Agent Workflow、显式状态机及 Agent Loop 等常见 Agent 实现方式；熟悉 Prompt 设计、结构化输出、上下文管理以及主流大模型 API 接入
- RAG 与知识库**：熟悉 RAG 完整链路，包括文档解析、文本切分、Embedding、召回、Rerank 和答案生成；熟悉向量检索、关键词检索、混合检索、元数据过滤等检索方案；熟悉 PDF、Word、Markdown 等非结构化文档处理；使用过 Pinecone、Milvus 等向量数据库
- 后端开发**：熟练使用 Python，熟悉 FastAPI、Pydantic、SQLAlchemy 等后端技术；熟悉 PostgreSQL、MySQL，具备关系型数据库模型及 REST API 设计经验；熟悉 Redis、Celery，具备缓存、异步任务和任务队列开发经验；了解接口幂等、异常重试、超时控制、服务降级等常见后端工程方案
- 工程化与开发工具**：熟悉 Linux 开发环境及常用命令；熟悉 Docker 容器化部署及基本服务运维；熟悉 Git 版本管理和常见团队协作流程；

项目经历

企业RAG 知识库问答系统

2023年03月 - 2023年07月

核心开发工程师

- 负责 PDF、Word、Markdown 等企业文档的解析、数据清洗及 Chunk 切分，并生成向量数据写入向量数据库。
- 构建向量检索与关键词检索结合的多路召回流程，并通过文档类型、业务部门等 Metadata 对候选结果进行过滤。
- 在召回结果后接入 Rerank 模型，对候选 Chunk 进行重新排序，提高进入生成阶段的上下文相关性。
- 将检索结果作为上下文提供给大模型生成答案，同时返回对应知识来源，并针对低相关结果增加拒答机制。
- 优化知识检索链路和异常处理流程，改善单一向量召回带来的低相关结果及错误回答问题。